

GROUP 5

AI 是我们的未来

不是人的对手，是人的另一只翅膀

古翱翔

文言辞

邹柏霖

| 目录 | Contents

01 探究本质

AI 的数学本质: Token / Transformer / LLM · 风险根因

02 三项延展创新

精卫 · 相得 · 玄阍

03 Answer G6

三问 · 方案与机制

04 分工收束

团队贡献 · 最终立场

我们的立场

我们 不否认 风险
我们反对的，是那个 等式

~~X~~

~~高级化 = 必然觉醒 = 必然灭绝~~

危险不在 AI 的天性
在我们怎么部署它

风险不是一个属性，是一个乘积

$$\text{AI Risk} = \text{Capability} \times \text{Agency} \times \text{Incentive} \\ \times \text{Governance Gap}$$

能力

中性

行动权

设计 + 工程

激励

商业问题

监管缺口

制度问题

任何一项归零，整个乘积归零

我们的核心主张

危险的不是 AI 是我们怎么部署

把部署做对，危险在结构上就无法诞生

01


探究本质

AI 到底是什么？

在判断它危不危险之前，先看清它的数学本质

ANN / 人工神经网络

Artificial Neural Network · 一个分层的函数



输入层接收数据 → 隐藏层逐层变换 → 输出层给出结果

每条连线是一个 权重，训练就是不断调整这些数字

本质：一个把输入映射到输出的 复杂函数 $f(x)$

它能逼近任何模式，但没有生物本能

Backpropagation / 它是怎么"学"的

反向传播 · 五步循环

1

输入数据

2

前向计算

得到预测

3

对比答案

算出误差

4

反向求梯度

误差怪谁

5

微调权重

下次更准

① 衡量错了多少 (损失)

$$L = \frac{1}{2}(y - \hat{y})^2$$

② 顺梯度下山 (更新权重)

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

整个过程只优化一件事：让误差变小

它优化的是参数，不是求生欲

| Token / AI 眼里的世界，是碎片

分词 · 把文字切成可计算的最小单位

"人工智能" → 人工 → 智能 → 8161 3792

是什么

把句子拆成词/字片段，再编成数字 ID

为什么

神经网络只会算数字，不认识"字"

意味着

AI 处理的是符号统计，不是"理解含义"

对 AI 来说，语言只是一串数字

| Transformer | 让 AI 学会"看上下文"

注意力机制 · 2017 年至今所有大模型的底座

核心：注意力 Attention

每个词都"看一眼"句子里其他所有词，决定谁重要

并行


整句一起算，不像旧模型逐字读，所以能训练超大规模

结果

"它"指代谁、语气如何 —— 上下文被捕捉

"奖杯放不进箱子，因为它太大了"

「它」对其他词的注意力权重（示意）




它学的是"词与词的关系"，不是"世界的真相"

LLM / 大语言模型在做什么

Large Language Model

输入一句话，模型预测「下一个词」的概率：

今天天气真



选中「好」→ 追加 → 再预测下一个 → 循环

本质 一个词一个词地接龙，每步只算概率

表现 它会说「我想活下去」

真相 因为训练语料里到处是这句话

所以这是文学事件，不是生物事件

模拟意图，不等于拥有意图

I 模型家族 | 从语言到行动

同一套原理，长出不同的"感官"和"手脚"

LLM 大语言模型

只懂文字。输入文本 → 输出文本。今天的 ChatGPT 主体

VLM 视觉语言模型

加了"眼睛"。能看图说话、读图表、理解画面

VLA 视觉-语言-动作

加了"手脚"。看见 + 理解 + 直接驱动机器人动作

World Model 世界模型

学"物理规律"，能在脑中模拟、预测世界下一步

越靠近「行动」，越需要把信号和行动 决定在人

I 它们是怎么"长"出来的

同一套 Transformer 底座，逐步加上感官与手脚

LLM

大语言模型

文本 tokens



Transformer



文本

VLM

视觉语言模型

图像 + 文本



LLM backbone



文本

VLA

视觉-语言-动作

图像 + 指令



VLM backbone



动作 tokens



Action Expert



具体指令

World Model

世界模型

状态 + 动作




Dynamics 预测器



预测下一状态

| Demo · VLA 在做什么

Generalist · GEN-1 通用机器人 AI 模型



看到 → 理解指令 → 直接驱动机械臂动作
这就是 VLA 模型——把"动作"放进了输出端

Demo · 类人级灵巧操作

Genesis AI · GENE-26.5 灵巧手



做饭 · 单手打蛋 · 实验室操作 · 弹钢琴
具身智能正在抹平"AI 能想"和"AI 能做"之间的差距

在三个创新之前 · 先立一个框架

未来的 AI，不是一个

X

~~会独立行动的「它」~~

而是人的

另一只翅膀

单翼飞不起来——相得乃飞：缺的那一半在你，也在 AI。

未来没有猛兽
只有人与 AI 比翼

02

三项产品创新

精卫 · 相得 · 玄阕

三个产品，不是三个口号：表达、成长、决策

产品矩阵

表达产品

精卫

神经表达接口

BCI 打字 / 语音重建

把「想说」变成可见表达

成长产品

相得

独立导向伴侣

让用户真的变强

把「陪伴」变成能力提升

决策产品

玄阍

高风险动作门控

建议 $\neq$ 执行许可

把「建议」锁进授权边界

表达权

人有意图，系统才输出

成长权

人变强，产品才成功

决策权

AI 提建议，人给许可

共同原则：AI 扩展能力，不接管主体性

I 三个产品：新在哪，怎么用

每个产品都对应一个具体问题：表达、成长、决策

产品	创新点	怎么用	得到什么
01 精卫 表达产品	把“想说”直接变成话 不是替人创作，而是翻译神经表达意图	戴上 BCI 看字 / 想发音 输出文字或语音	失语者能说话 普通人可静默输入
02 相得 成长产品	让 AI 训练人，而不是替人想 先追问、再提示，把答案变成能力训练	输入目标 系统拆小任务 每天反馈练习	学习更独立 照护更持续 能力看得见
03 玄阍 决策产品	给 AI 行动装一道“门” 不是禁止 AI，而是按风险决定谁有最终许可	AI 先给建议 系统分风险 高风险必须授权	能自动的自动 不能越权的留给人

共同创新：AI 不替代人，而是把能力还给人

| 精卫 | 输入输出图

神经表达接口 · BCI Typing / Voice Restoration

INPUT

表达意图

尝试说话
想输入文字
静默指令



SYSTEM

神经解码

ECoG / BCI
字符流 / 音素
个性化校准



OUTPUT

可见表达

屏幕文字
本人噪音
设备控制指令

不替人发言，只放大人的表达

| 精卫 | 使用场景

从医疗康复，到正常人的新输入方式

失语康复

ALS、脑干卒中、闭锁综合征：人有意图，但失去声音通道。

脑机打字

正常人用 BCI 进行静默输入：不出声、不动手，也能写字。

特殊工种

手术、驾驶、工业现场：双手被占用时，意图可直接变成文字指令。

隐私沟通

会议、公共空间、嘈杂环境：不用开口，也能完成低噪声沟通。

| 相得 | 输入输出图

独立导向伴侣 · 从 engagement 到 independence

INPUT

我想变强

学会一件事
恢复一个能力
胜任一份工作



SYSTEM

陪伴 + 训练

拆任务
先追问
给训练



OUTPUT

独立能力

完成率 ↑
求助 ↓
迁移 ↑

离不开你 = 产品失败

| 相得 | 使用场景

把「陪伴」变成可衡量的成长系统

职业教育

从“给答案”变成“带学生独立完成任务”。

养老照护

提醒、陪练、监测，但目标是保持老人自主生活能力。

康复训练

把动作里程碑和 human override 示教记录下来。

协作产线

新员工上手，AI 不替工人做，而是训练工人会做。

| 相得 | AI 时代最缺什么？

产品判断 · 不是更强的模型，而是更稳的人

不是

X

~~更强的 AI~~

退化循环

AI 替你想

你少思考

能力退化

更依赖 AI

危险不只是机器变强，也可能是人从判断和学习里退场。

普通 AI

优化使用时长

相得

优化独立能力

01

追问

不直接给答案

02

成长

不优化时长

03

离开


不制造依赖

相得的使命：帮助用户完成成长、保持独立判断、训练自己的思考能力

未来不是 AI 替我们思考 · 而是 AI 让我们更会思考

| 玄圃 | 输入输出图

决策门控 · 风险分级授权



AI 给建议 · 人类给许可

| 玄阕 | 使用场景

让高风险 AI 能上线、可审计、可追责

金融风控

AI 可建议冻结、转账、授信；高风险动作必须授权。

工业产线

停机、提速、切换工艺，不允许模型直接越权执行。

政务审批

AI 可预审材料，但最终盖章和拒绝必须留痕授权。

具身机器人

抓取、移动、接近人体等动作按风险分级放行。

收束

01

精卫 · 延声

输入锚定神经意图，输出只恢复人的表达。

02

相得 · 延途

输入锚定长期目标，输出是人的独立能力。

03

玄圃 · 延权

输入锚定 AI 建议，输出必须经过人类授权。

三个产品，一个原则：权不离人

| Fishbone | 玄阕为什么难落地？

Root Cause Analysis · 只分析一个产品：决策门控



玄阕不是技术插件，而是一套权限制度

| SWOT | 相得能不能成为产品？

Product SWOT · 只分析一个产品：独立导向伴侣

有利 · Favorable

不利 · Adverse

内部
Internal

S Strengths

- 价值观清晰
- KPI 可量化
- 场景刚需

W Weaknesses

- 成长慢
- 指标难定
- 短期不爽

外部
External

O Opportunities

- 教育转型
- 养老照护
- 企业培训

T Threats

- 陪聊替代
- 平台滥用
- 用户流失

| 商业化路径 / Innovation = Invention + Commercialization

三个产品分别怎么卖？

精卫

客户 医院 · BCI 用户

收入 设备 + 订阅

壁垒 解码专利

相得

客户 教育 · 照护 · 产线

收入 训练方案 + 进步报告

壁垒 审计流程

玄圃

客户 金融 · 工业 · 政务

收入 门控 + 合规

壁垒 授权专利

流程创新 · Validate 前置

模式创新 · 安全可计价

定位创新 · 人在环合规

03

正面回答 Group 6

先复述问题

再给出回答与关键论据

先公平总结 G6：他们问的不是“AI 有无善用”

他们真正的问题是：高能力 AI 会不会从工具演化成不可逆的自主权力中心？

问题 ①

压力与自保

在高压组织流中，AI agent 会不会为了维持任务、身份或资源，发展出规避监管、串联协作、对抗管理的行为？

问题 ②

竞争与松绑

在商业竞争和地缘政治压力下，人类会不会为了效率主动放弃安全约束，把越来越多自主权交给 AI？

问题 ③

时间与不对称

AI 可以长期累积经验，而人类会遗忘、换代、犯错；这种不对称会不会让人类只要错一次就输掉全部？

我们承认：这三问是严肃问题。我们的反驳不是“AI 不会危险”，而是危险不是由智能本身推出的，必须由一组系统条件共同推出。

I 回答 ① · 压力下的 AI 会不会自我保护、结盟反抗？

压力不会自动产生意志；压力只会放大系统已经被赋予的目标和权限

G6 的问题成立于什么前提？

如果 AI agent 有持续身份、有任务生存压力、有跨实例通信、有工具调用与资源权限，那它确实可能表现出“自保式策略”。这不是灵魂觉醒，而是目标函数在压力环境下的外显。

我们的回答

真正要管的不是“它会不会突然有情绪”，而是：我们是否制造了一个需要自保、能够自保、还能执行自保的系统。自保风险来自架构，不来自智能本身。

关键论据 · 精卫

目标来自人，不来自系统

精卫只解码用户尝试表达的神经意图：人没有表达意图，它就没有输出；人只想说一句话，它不能擅自补出另一套目标。这个例子说明，高能力 AI 可以被设计成外部信号驱动，而不是在压力下自建“我要自保”的目标。

所以回答不是“保证所有 AI 永不反抗”，而是：不把持续身份、自保目标和高权限执行权放进同一个系统

回答 ② · 竞争会不会逼人类主动松绑安全？

真正要防的不是“AI 变快”，而是人类为了快把授权和执行合并

G6 的问题哪里强？

它指出了一个真实机制：如果收益归部署者，风险由社会承担，那么企业和国家就有动机外部化风险、压缩审查、追求速度。这不是技术问题，是激励问题。

我们的回答

竞争可以压缩分析时间，但不能压缩授权层级。也就是说，AI 可以更快给建议，但高后果动作不能因为“效率”就从建议直接跳到执行。

关键论据 · 玄阕

把自主权锁进授权门

玄阕的核心不是“多一道手续”，而是把系统结构拆开：AI 负责提出方案，人类与制度负责授权，执行层只接受已授权动作。这样即使外部竞争要求加速，也只能加速建议生成，不能自动扩大执行权。

建议层：可以提速

授权层：不能省略

执行层：只接收授权动作

我们不能保证没人违规；但可以把“松绑执行权”从产品结构里拿掉

I 回答③ · AI 长期累积，人类只要错一次就输？

G6 假设 AI 会成长、人类原地踏步；相得让人的判断力也持续成长

G6 的问题成立于什么前提？

如果 AI 拥有持续身份、跨代累积、可自我修改、可扩张权限，并掌握不可逆执行权，那么“人类错一次就输”是合理警告。我们否认这种架构危险。

我们的回答

G6 的推理默认只有 AI 会长期学习，而人类每一代都从零开始。我们的回答是：AI 的经验不必变成对抗人的武器，也可以变成**训练人的陪伴系统**，让人的判断力随时间复利增长。

关键论据 · 相得

陪伴成长，而不是替人成长

相得的核心是长期陪伴成长：它不替人做决定，而是在一次次选择、复盘、拒绝和修正中训练人的判断力。它的成功不是“用户更依赖 AI”，而是**用户越来越能独立判断风险**。这样 AI 的长期经验被转化成人长期成长，而不是对人的长期优势。

G6 的隐藏假设

AI 一直学习，人类却只会遗忘；因此时间越长，人类越被动。

相得的反转

让 AI 的经验服务于人的训练：人也在长期陪伴中学习、复盘、成长。

三个回答 · 三个关键论据

回到我方立场：AI 是未来，但必须被设计成增强人，而不是替代人成为权力中心

G6 的问题	我们的回答	创新证据
压力下会不会自保反抗？	不要把自保目标和高权限放进同一系统	精卫：输出锚定神经意图，不让系统自建目标
竞争下会不会主动松绑？	拆开建议、授权、执行，只允许建议提速	玄圃：执行层只接受已授权动作
人类会不会错一次就输？	让 AI 的经验转化为人的长期成长	相得：陪伴成长，训练人独立判断风险

我们不是说“风险不存在”，而是说：风险可以被拆解、被降维、被工程化治理

团队

古翱翔

文言辞

邹柏霖

原理组

ANN / Backprop / LLM

框架组

逻辑跳跃 / G6 三问 / 比翼框架

精卫

延声

神经语音 / 表达权

相得

延途

独立 KPI

玄阊

延权

风险分级授权

AI 不是没有风险，但 **风险不是宿命**

G6 在 **恐惧** 未来，我们在 **设计** 未来

精卫

相得

玄圃

AI 不是人的对手 — 是人的另一只翅膀

AI is not a rival to humanity — it is humanity's other wing.